


Vzorčenje v visokih dimenzijah: Mikrokanonični Hamiltonski Monte Carlo



Jakob Robnik


mentor: Uroš Seljak

ostali sodelavci: Eva Silverstein, Bruno De Luca,
Jaime Ruiz Zapatero, Reuben Cohn-Gordon,
Qijia Jiang, Adrian Bayer, Rohith Karur,



Vzorčenje

Naloga: generiraj vzorce, porazdeljene po dani porazdelitvi.




Zakaj je to pomemben problem?


Integriranje

Število izračunov funkcije za neko natančnost:

$O(n)$




$O(n^2)$



...

$O(n^d)$


Monte Carlo: $\int f(x)p(x)dx \stackrel{x_i \sim p}{\approx} \frac{1}{n} \sum_{i=1}^n f(x_i)$



$O(n^2)$

1. Marginalna porazdelitev


$$p(\mathbf{y}) = \int p(\mathbf{y}, \mathbf{z}) d\mathbf{z}$$




	smrtno	ni smrtno
kobra	7 (5 %)	12 (8.5 %)
krait	8 (5.7 %)	13 (9.2 %)
Russellov gad	22 (15.6 %)	52 (36.9 %)
žagast gad	3 (2.1 %)	27 (19.1 %)
marginalno	26 %	74 %

Chaudhari, Tejendra S., et al. "Predictors of mortality in patients of poisonous snake bite: experience from a tertiary care hospital in central India." *International journal of critical illness and injury science* 4.2 (2014): 101.

□ Initial conditions of the Universe



□ Large Scale Structures




Simulating the Universe in TensorFlow
March 06, 2020
Guest post by Chirag Modi, François Lanusse, Mustafa
Mustafa, Uroš Seljak


\mathbf{x} = (začetni pogoji, gostota snovi, enačba stanja za temno energijo, ...)

Bayesovsko sklepanje: $p(\mathbf{x}|\text{data}) \propto p(\text{data}|\mathbf{x})p(\mathbf{x})$

Standard Neural Network




Bayesian Neural Network



2. Kvantna kromodinamika na mreži

- Naloga: izračun **mase sestavljenih delcev** (npr. protona) iz osnovnih zakonov
- **Integral prek vseh možnih konfiguracij** fermionskega in gluonskega kvantnega polja
- Diskretiziramo prostor na mreži, polja aproksimiramo z visoko-dimenzionalnimi vektorji
- **$>10^9$ dimenzionalen integral**, za izračun integranda potrebuješ **10^5 jeder**, to področje porablja **40% vse superračunalniške moči v ZDA**




Kako vzorčiti?

Intermezzo: Hamiltonova dinamika

- Imejmo dva vektorja $\mathbf{x}, \boldsymbol{\Pi} \in \mathbb{R}^d$ in skalarno funkcijo $H(\mathbf{x}, \boldsymbol{\Pi})$
- Naj se časovno spreminjata po diferencialnih enačbah:

$$\frac{d\mathbf{x}}{dt} = \frac{\partial H(\mathbf{x}, \boldsymbol{\Pi})}{\partial \boldsymbol{\Pi}} \quad \frac{d\boldsymbol{\Pi}}{dt} = -\frac{\partial H(\mathbf{x}, \boldsymbol{\Pi})}{\partial \mathbf{x}}$$

1. $\mathbf{x}(t), \boldsymbol{\Pi}(t)$ vedno ostaneta na ploskvi konstantnega H
2. **Ergodična hipoteza:** $p(\mathbf{x}, \boldsymbol{\Pi})$ je uniformna porazdelitev, omejena na ploskev konstantnega H = **mikrokanonična porazdelitev**




Znamo vzorčit iz **mikrokanonične** porazdelitve!

Je to dovolj za vzorčenje iz **poljubne** porazdelitve?

Mikrokanonični Hamiltonski Monte Carlo (MCHMC)

- Želimo vzorčit iz $p(\mathbf{x})$
- Vpeljemo dodatno spremenljivko $\mathbf{\Pi}$ in funkcijo $H(\mathbf{x}, \mathbf{\Pi})$
- Simuliramo Hamiltonovo dinamiko \rightarrow konvergiramo k mikrokanonični porazdelitvi
- H nastavimo tako, da je **marginalna x-porazdelitev** $p(\mathbf{x})$:


$$H = \frac{d}{2} \log \frac{|\mathbf{\Pi}|^2}{d} - \log p(\mathbf{x})$$




Implementacija

1. **Integracija Hamiltonovih enačb**: kako izbrat časovni korak?
napaka na energiji \leftrightarrow pristranost vzorcev
2. **Ergodičnost počasna ali je ni** \rightarrow dodajmo dekoherenco momenta! (pogoj tipa No U-turn)

Hamiltonova dinamika + šum na momentu




Hamiltonova dinamika




Canonical HMC

$$p(\mathbf{x}, \mathbf{\Pi}) \propto e^{-H(\mathbf{x}, \mathbf{\Pi})}$$



Microcanonical HMC

$$p(\mathbf{x}, \mathbf{\Pi}) \propto \delta(H(\mathbf{x}, \mathbf{\Pi}) - E)$$



HMC

Initialize x

For i in range(n)

u[k] \sim N(0, 1)

xold = x

For j in range(L):

u = update_momentum(stepsize/2, u, grad_nlogp(x))

x = update_position(stepsize, x, u)

u = update_momentum(stepsize/2, u, grad_nlogp(x))

x = accept/reject(xold, x, energy change)

save(x)

```
def update_momentum(eps, u, g):  
    return u - eps * g
```

MCHMC

Initialize x

For i in range(n):

u[k] \sim N(0, 1)

u = u / norm(u)

For j in range(L):

u = update_momentum(stepsize/2, u, grad_nlogp(x))

x = update_position(stepsize, x, u)

u = update_momentum(stepsize/2, u, grad_nlogp(x))

save(x)


```
def update_momentum(eps, u, g):  
    g_norm = sqrt(sum(square(g)))  
    e = - g / g_norm  
    ue = dot(u, e)  
    delta = eps * g_norm / (d-1)  
    zeta = exp(-delta)  
    uu = e * (1-zeta)*(1+zeta + ue * (1-zeta)) + 2*zeta* u  
    return uu / sqrt(sum(square(uu)))
```


Želimo **natančnost** pričakovanih vrednosti: $\int f(\mathbf{x})p(\mathbf{x})d\mathbf{x} \approx \frac{1}{n} \sum_{i=1}^n f(\mathbf{x}_i)$


ESS = “učinkovitost” = “**natančnost**” / “**računska cena**”
= **efektivno število vzorcev** / **število evaluacij** ∇p

HMC: $O(d^{-1/4})$

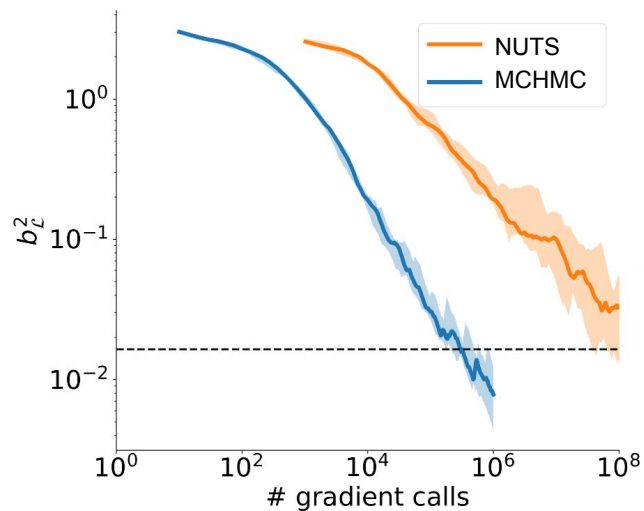
MCHMC: $O(1)$



Učinkovitost neodvisna od dimenzije!




1000-dimenzionalna Cauchy-jeva porazdelitev



Paralelno vzorčenje

- Namesto **veliko korakov z eno verigo**, lahko delamo **malo korakov z več verigami**
- Odlično za GPU in clustre CPU-jev





	NUTS	ChEES	MEADS	MCLMC
Banana	320	264	390	22
Ill Conditioned Gaussian	9846	5138	5520	402
Sparse Logistic Regression	2716	1168	610	298
Brownian Motion	2159	600	410	122
Item Response Theory	1162	537	790	454

Vzorčenje ni več drago!

Table 1: Grads to low max bias ($b_{\max}^2 = 0.01$), normalized per chain.

Visoko-dimenzionalni problemi



- Napoved vremena
- Kvantna kromodinamika
- Bayesovsko sklepanje
- Bayesovske nevronske mreže
- Molekularna dinamika



- Python (jax) in C++: <https://github.com/JakobRobnik/MicroCanonicalHMC>
- Julia: <https://github.com/JaimeRZP/MicroCanonicalHMC.jl>
- Spletna stran s tutoriali: <https://main--zesty-daffodil-572c7d.netlify.app/>
- Delamo na vključitvi v PPL-je kot so numpyro, STAN in pymc3.
- Članki:
 - Robnik, De Luca, Silverstein and Seljak, *Microcanonical Hamiltonian Monte Carlo*, 2022 (arXiv: 2212.08549)
 - Robnik and Seljak, *Microcanonical Langevin Monte Carlo*, 2023 (arXiv: 2303.18221)
 - Bayer, Seljak and Modi, *Field-Level Inference with Microcanonical Langevin Monte Carlo*, 2023 (arXiv: 2307.09504)

Prvi poskus: Metropolis-Hastings algoritem

- V vsakem koraku predlagamo nov vzorec $x_{n+1} \sim q(\cdot|x_n)$ in ga sprejmemo z verjetnostjo $\min\{1, \frac{p(x_{n+1})q(x_n|x_{n+1})}{p(x_n)q(x_{n+1}|x_n)}\}$.
- Problem 1: če je korak **predolg**, so predlogi zavrnjeni, če je **prekratek**, se počasi premikamo
- Problem 2: ESS = **O(1/d)**

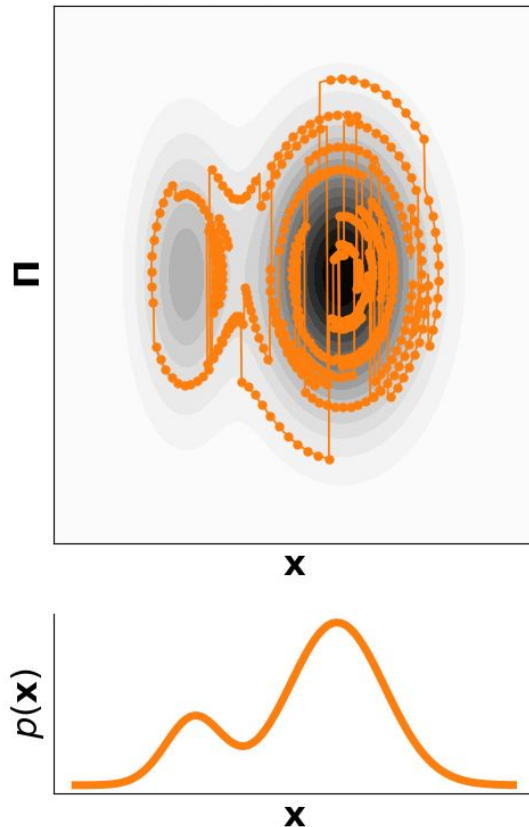



Hamiltonski Monte Carlo (HMC)

- Želimo vzorčit iz $p(\mathbf{x})$
- Vpeljemo dodatno spremenljivko $\mathbf{\Pi}$ in funkcijo $H(\mathbf{x}, \mathbf{\Pi})$
- Hamiltonova dinamika omogoča učinkovito vzorčenje **mikrokanonične** porazdelitve
- Če dodamo občasno **prevzorčenje** momenta konvergiramo h **kanonični** porazdelitvi $p(\mathbf{x}, \mathbf{\Pi}) \propto e^{-H(\mathbf{x}, \mathbf{\Pi})}$
- H nastavimo tako, da je **marginalna x-porazdelitev** $p(\mathbf{x})$:

$$H = \frac{1}{2}|\mathbf{\Pi}|^2 - \log p(\mathbf{x})$$

Canonical HMC
 $p(\mathbf{x}, \mathbf{\Pi}) \propto e^{-H(\mathbf{x}, \mathbf{\Pi})}$

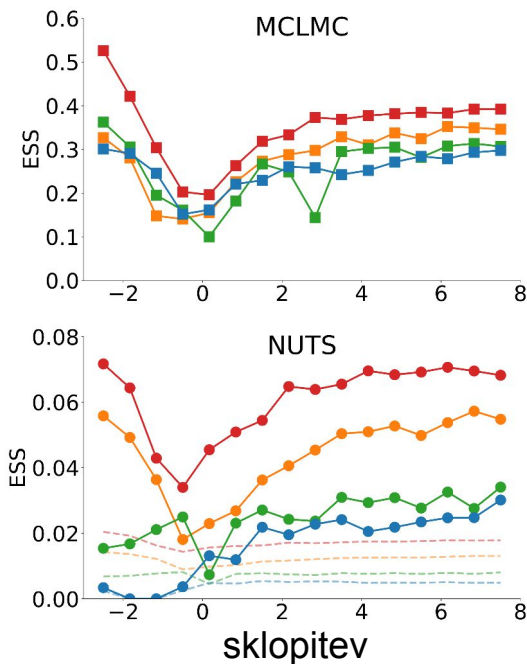







Kako to deluje na pravih problemih?

ϕ^4 teorija polja

fazni prehod



2. Statistična fizika: Boltzmanova porazdelitev

$$p(\boldsymbol{x}, \boldsymbol{\Pi}) \propto e^{-H(\boldsymbol{x}, \boldsymbol{\Pi})/T}$$

Formacija proteinov

